APRENDIZAJE FEDERADO POR TRANSFERENCIA ENTRE PLANOS ANATÓMICOS

Pablo Jesús Delgado Muñoz *María Vázquez López* *Paola Gambero Díaz*

Universidad de Málaga

ABSTRACT

En este trabajo abordamos el Proyecto 6 de la asignatura, que plantea un escenario de aprendizaje federado por transferencia (FTL) para clasificar imágenes MRI-FLAIR como Esclerosis Múltiple (EM) o control. Los cuatro hospitales simulados usan todos la misma modalidad, pero cada uno adquiere las imágenes en un plano anatómico distinto: axial, coronal, sagital (o mixto). Esto introduce un cambio de dominio visual que convierte el problema en FTL en lugar de aprendizaje federado horizontal clásico.

Antes de entrenar caracterizamos la heterogeneidad entre hospitales en tres espacios distintos y encontramos que la diferencia real no está en los píxeles sino en el espacio del gradiente, donde el coseno medio entre clientes es 0,74. Comparamos FedAvg y FedProx frente a cotas de entrenamiento local y centralizado, usando ResNet-18 sin preentrenamiento. FedAvg converge en 5 rondas con AUC = 0,998 y F1 = 0,969. FedProx con $\mu = 0{,}1$ necesita 10 rondas para obtener resultados similares (AUC = 0,9996, F1 = 0,980) debido a que su término proximal le cuesta arrancar cuando el modelo global inicial está en un estado degenerado. La conclusión principal es que FedAvg es la opción más robusta y eficiente para este nivel de heterogeneidad.

Palabras clave: aprendizaje federado por transferencia, imagen médica, MRI-FLAIR, FedAvg, FedProx, ResNet-18.

1. INTRODUCCIÓN

El aprendizaje federado (AF) permite entrenar un modelo compartido sobre datos repartidos en varios clientes sin necesidad de moverlos a un servidor central, intercambiando solo los parámetros del modelo [1, 7]. Esto resulta muy útil en el entorno sanitario, donde los datos de los pacientes están protegidos por normativas como el RGPD que impiden su centralización fuera del centro de origen [3]. Además, un único hospital suele tener demasiado pocos datos etiquetados para entrenar un modelo de aprendizaje automático fiable por sí solo [8]. La federación ofrece una solución: aprovechar los datos de todos sin que nadie tenga que cederlos.

El caso más estudiado en la materia es el aprendizaje federado horizontal (HFL), donde todos los clientes trabajan con el mismo tipo de datos y la misma tarea, y solo difieren en las muestras concretas que tienen. El reto en HFL es la heterogeneidad estadística: si los datos de cada cliente tienen distribuciones muy distintas (escenario no-IID), la media de pesos puede converger más lento o incluso hacia un modelo peor que los locales. Sin embargo, en la práctica hospitalaria existe otro tipo de heterogeneidad más difícil de manejar: distintos hospitales pueden adquirir las mismas imágenes con protocolos diferentes, lo que introduce diferencias visuales entre clientes. Cuando los clientes ven el mismo tipo de imagen en modalidad pero con características visuales distintas, como ocurre al cambiar el plano de corte anatómico, hablamos de aprendizaje federado por transferencia (FTL). La clave es que el espacio de etiquetas $Y^{(k)}$ es igual en todos los clientes pero el espacio de entrada $X^{(k)}$ no lo es, porque el mismo cerebro visto desde axial, coronal o sagital genera imágenes visualmente muy diferentes para una red convolucional.

Contexto clínico

La Esclerosis Múltiple (EM) es una enfermedad inflamatoria desmielinizante del sistema nervioso central que afecta a más de dos millones de personas en el mundo. Su diagnóstico se apoya en la resonancia magnética, especialmente en secuencias FLAIR (*Fluid-Attenuated Inversion Recovery*), donde las lesiones desmielinizantes periventriculares aparecen como hiperintensidades bien delimitadas al suprimirse la señal del líquido cefalorraquídeo. Distintos centros adquieren estos volúmenes en planos diferentes según su protocolo habitual: el axial es el más habitual para cuantificar la carga lesional total, el coronal se usa para la fosa posterior y los lóbulos temporales, y el sagital para evaluar el cuerpo calloso. Esta variabilidad de planos entre centros es exactamente el escenario FTL que estudiamos: la tarea clínica es la misma en todos los hospitales, pero la apariencia de las imágenes cambia radicalmente de un plano a otro.

En este proyecto simulamos cuatro hospitales que trabajan todos con secuencias FLAIR para clasificar EM frente a control, pero cada uno usa un plano de corte diferente. El objetivo es analizar si un modelo federado puede integrar la información de estas cuatro vistas y generalizar correctamente a todas ellas, comparando qué algoritmo de AF lo hace mejor con menor coste de comunicación.

Table 1. Distribución del conjunto de datos por hospital. La columna EM es la fracción de casos EM en entrenamiento para los hospitales y en test para la fila Global.

Hospital	Plano	Slices train	Slices test	EM
H1	axial	3 458	1 183	0,605
H2	coronal	4 142	1 417	0,605
H3	sagital	3 458	1 001	0,605
H4	mixto	3 583	1 073	0,619
Global	—	—	4 674	0,459

Trabajo relacionado. McMahan *et al.* [1] propusieron FedAvg, que promedia los pesos de los clientes ponderando por número de muestras y es el algoritmo de referencia en AF. Li *et al.* [2] analizaron los principales retos del AF en escenarios no-IID, entre ellos el *client drift*, que ocurre cuando los clientes se alejan demasiado del modelo global al entrenar localmente varias épocas. Para corregirlo, el mismo grupo propuso FedProx [4], que añade un término proximal a la pérdida local limitando cuánto puede alejarse cada cliente del modelo global. En imagen médica federada, Kaissis *et al.* [3] discuten las implicaciones de privacidad y los retos de robustez específicos del dominio clínico. La arquitectura base usada, ResNet-18, fue propuesta por He *et al.* [5] y es un estándar en tareas de clasificación de imagen médica.

El informe se organiza así: la Sección 2 define el problema como red de AF; la Sección 3 describe los algoritmos y la implementación; la Sección 4 presenta los experimentos con todos los resultados; la Sección 5 recoge las conclusiones y el trabajo futuro.

2. FORMULACIÓN DEL PROBLEMA

Conjunto de datos

Los datos provienen de la base MRI-MS-KDE, que contiene cortes 2D de MRI en modalidad FLAIR de pacientes con EM y controles sanos en tres planos anatómicos. Todas las imágenes pasan por un preprocesado KDE (*Kernel Density Estimation*) que normaliza el histograma de intensidades. Esto elimina las diferencias de contraste entre equipos y deja como única variación inter-cliente el plano de corte. Las etiquetas son por paciente: todos los cortes de un paciente con EM se etiquetan como EM, aunque en algún corte concreto no haya lesión visible.

La partición federada asigna un plano a cada hospital simulado (Tabla 1). La proporción de casos EM en entrenamiento es del 60 % en todos los hospitales, así que no hay desbalance de clases entre clientes. La heterogeneidad es puramente visual.

Red de aprendizaje federado

Nodos. Cada nodo $k \in \{1, 2, 3, 4\}$ es un hospital simulado con sus propios cortes de un plano anatómico concreto. Verificamos que no hay solapamiento de pacientes ni entre hospitales ni entre las particiones de entrenamiento y test.

Modelos locales. Todos los clientes usan la misma arquitectura: ResNet-18 sin preentrenamiento [5], con la última capa totalmente conectada sustituida por una proyección lineal a un único logit. Las imágenes se cargan en escala de grises, se replican a 3 canales para encajar con la entrada esperada por la ResNet, y se redimensionan a 224×224 px para eliminar diferencias de resolución entre planos. El número total de parámetros es $|\mathbf{w}| = 11{,}177$ M.

Función de pérdida local. Usamos BCEWithLogitsLoss, que aplica sigmoide al logit internamente antes de calcular la entropía cruzada binaria, lo que es numéricamente más estable que hacerlo por separado:

$$\mathcal{L}^{(k)}(\mathbf{w}) = -\frac{1}{n_k}\sum_{i=1}^{n_k}\big[y_i \log \sigma(f_{\mathbf{w}}(\mathbf{x}_i)) + (1-y_i)\log(1-\sigma(f_{\mathbf{w}}(\mathbf{x}_i)))\big]. \tag{1}$$

Por qué este escenario es FTL. Todos los hospitales resuelven la misma tarea ($Y^{(k)} = Y$ para todo k), pero cada uno observa el cerebro desde un plano distinto, por lo que $X^{(k)} \neq X^{(k')}$. La distribución marginal de entrada $P(X)$ cambia entre clientes mientras que $P(Y|X)$ es la misma. Eso define FTL: el modelo global tiene que transferir lo aprendido en un plano a los demás, no solo promediar parámetros de clientes con datos similares como en HFL.

Topología. Usamos una topología estrella centralizada: los $K = 4$ clientes solo se comunican con el servidor. Al comienzo de cada ronda el servidor envía $\mathbf{w}_t^g$ a todos los clientes; estos entrenan E épocas localmente y devuelven $\mathbf{w}_{t+1}^{(k)}$. Las aristas tienen peso $n_k / \sum_j n_j$, proporcional al número de muestras.

Caracterización de la heterogeneidad

Para entender mejor el problema antes de entrenar, cuantificamos la diferencia entre hospitales en tres espacios distintos. Las **distancias entre histogramas de intensidad** (TV, Hellinger, Wasserstein-1) miden la diferencia a nivel de píxel sin tener en cuenta la estructura espacial. Las **distancias entre embeddings** de una ResNet-18 sin entrenar (Fréchet, coseno entre medias de características) comparan las representaciones en el espacio de características. Las **similitudes de gradiente** (coseno, norma de la diferencia) miden cómo de parecidas son las actualizaciones que cada cliente haría si partiesen del mismo modelo.

Los resultados de la Tabla 2 y la Figura 1 revelan algo importante: el preprocesado KDE hace que los

Table 2. Resumen de heterogeneidad (media de los 6 pares posibles).

Métrica	Espacio	Valor medio
Total Variation entre histogramas	Píxeles	0,015
Hellinger entre histogramas	Píxeles	0,022
Wasserstein-1 entre histogramas	Píxeles	0,53
Distancia Fréchet entre embeddings	Features	86,3
Coseno entre embeddings ResNet	Features	0,977
Coseno de gradiente local	Gradientes	0,739
$\|\nabla_i - \nabla_j\|_2$	Gradientes	5,11

hospitales sean casi idénticos en píxeles (TV = 0,015) y también muy similares en el espacio de representaciones aprendidas (coseno embeddings = 0,977). Sin embargo, en el espacio del gradiente la similitud media baja a 0,739, con un mínimo de 0,525 entre H1 axial y H3 sagital. Si nos hubiésemos quedado solo con los histogramas habríamos concluido que los clientes son casi iguales, cuando en realidad difieren bastante en cómo optimizan el modelo.

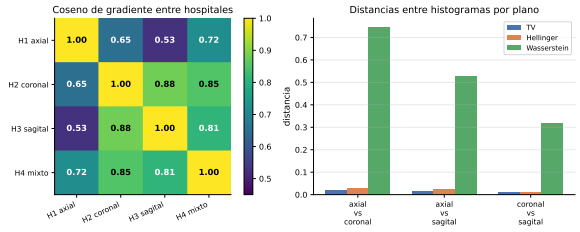


Fig. 1. Izquierda: coseno entre gradientes locales de cada par de hospitales. Derecha: distancias entre histogramas de intensidad por par de planos.

3. MÉTODOS

Medida de variación

Para cuantificar la diferencia entre modelos de distintos clientes usamos la distancia euclídea cuadrada entre sus parámetros:

$$\phi(\mathbf{w}^{(i)} - \mathbf{w}^{(j)}) = \|\mathbf{w}^{(i)} - \mathbf{w}^{(j)}\|_2^2. \tag{2}$$

Esta medida aparece de forma explícita en el término proximal de FedProx.

Algoritmos federados

Llamamos $\mathbf{w}_t^g$ a los pesos globales al comienzo de la ronda t y $\mathbf{w}_{t+1}^{(k)}$ a los del cliente k después de E épocas locales con Adam ($\eta = 10^{-4}$).

FedAvg [1]. El servidor calcula la media de los pesos locales ponderando por el número de muestras de cada cliente, sin ningún tipo de regularización ni memoria entre rondas:

$$\mathbf{w}_{t+1}^g = \sum_{k=1}^{K} \frac{n_k}{\sum_j n_j} \mathbf{w}_{t+1}^{(k)}. \tag{3}$$

Es el algoritmo de referencia y el punto de partida para comparar cualquier variante.

FedProx [4]. Modifica la pérdida local añadiendo un término proximal que limita cuánto puede alejarse cada cliente del modelo global:

$$\mathcal{L}_{\text{prox}}^{(k)}(\mathbf{w}) = \mathcal{L}^{(k)}(\mathbf{w}) + \frac{\mu}{2}\|\mathbf{w} - \mathbf{w}_t^g\|_2^2. \tag{4}$$

La agregación en el servidor es la misma que FedAvg; la diferencia está solo en el entrenamiento local. Se implementa en `train_utils.py`: cuando `mu > 0` se guarda una copia de $\mathbf{w}_t^g$ antes del entrenamiento local y se añade el término proximal a la pérdida en cada batch.

Cotas de referencia

Entrenamos dos baselines. El *local-only* entrena un modelo por separado en cada hospital durante $T \times E$ épocas, sin comunicación alguna; cada uno de esos cuatro modelos se evalúa después sobre el test global, igual que los métodos federados. Si el modelo federado no supera al local-only, la federación no aporta nada. El *centralizado* junta todos los datos de los cuatro hospitales y entrena un único modelo con el mismo presupuesto de cómputo; funciona como cota superior de referencia, aunque en la práctica sería imposible por razones de privacidad. En general no cabe esperar que un modelo federado supere al centralizado, que dispone de todos los datos juntos.

Infraestructura

La implementación usa Flower [6] con PyTorch sobre GPU NVIDIA RTX serie 4000. Los cuatro clientes se ejecutan como actores Ray de forma secuencial. Para reproducibilidad, la semilla de cada cliente y ronda se calcula como `seed_base + cid + round`.

Hiperparámetros

La Tabla 3 recoge la configuración completa. Todos los algoritmos usan el mismo presupuesto de cómputo para poder compararlos de forma justa. Entrenamos sin pesos preentrenados porque, en caso contrario, los algoritmos saturan el AUC en torno a 1 desde la primera ronda y no se puede distinguir cuál funciona mejor.

Métricas de evaluación

Usamos AUC-ROC (robusto al umbral y al desbalance de clases), F1-score con umbral 0,5, y sensibilidad y especificidad por separado. La equidad entre hospitales se mide con $\sigma(\{AUC_k\})$: cuanto más bajo, más

Table 3. Hiperparámetros del experimento (ResNet-18 sin preentrenamiento).

Parámetro	Valor	Comentario
Inicialización	pesos aleatorios	sin preentrenamiento
Épocas locales E	2	por ronda y cliente
Tasa de aprendizaje	10^{-4}	Adam
Tamaño de batch	32	
Gradient clipping	1,0	evita gradientes explosivos
Weight decay	10^{-4}	regularización L2
Semillas	$\{42, 123\}$	dos repeticiones
μ FedProx	0,1	término proximal
Rondas FedAvg	5	
Rondas FedProx	10	necesita más para converger

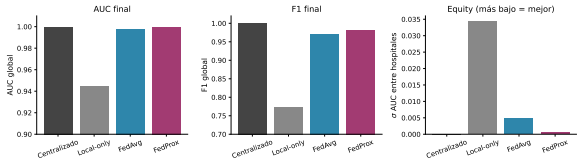


Fig. 2. Comparativa de AUC, F1 y equidad finales entre todos los métodos.

uniforme el rendimiento entre clientes. El coste de comunicación lo medimos como los MB que cada cliente intercambia con el servidor en cada ronda (subida y bajada del modelo).

4. EXPERIMENTOS NUMÉRICOS

Resultados globales

La Figura 2 y la Tabla 4 muestran las métricas finales sobre el test global de los tres planos. El centralizado alcanza un resultado casi perfecto. El local-only, en cambio, cae a AUC = 0,945 y F1 = 0,774: cada uno de sus cuatro modelos ha entrenado solo con un hospital, y los tres que vieron un único plano fallan al evaluarse sobre el test global, que mezcla los tres. Los algoritmos federados se acercan mucho más al centralizado, porque su modelo único ha visto los cuatro hospitales. Entre ellos, FedAvg es el mejor en términos de eficiencia: alcanza AUC = 0,998 y F1 = 0,969 en solo 5 rondas. FedProx llega a resultados algo mejores (AUC = 0,9996, F1 = 0,980), pero necesita 10 rondas, lo que supone el doble de coste en comunicación.

Table 4. Métricas finales sobre el test global.

Método	AUC	F1	Sen / Spe	Equity
Centralizado	1,0000	0,9995	0,9995 / 0,9996	0,0000
Local-only	0,9451	0,7739	0,9438 / 0,5295	0,0343
FedAvg (5 r.)	$0{,}998 \pm 0{,}001$	$0{,}969 \pm 0{,}009$	0,984 / 0,960	0,005
FedProx (10 r.)	$0{,}9996 \pm 0{,}0001$	$0{,}980 \pm 0{,}008$	0,994 / 0,970	0,001

Convergencia

La Figura 3 muestra las trayectorias de AUC y val_loss. FedAvg sube a AUC alto ya en la primera ronda; su val_loss oscila en las primeras rondas, con un pico en la ronda 1, antes de bajar hasta 0,06–0,11 en la ronda 5. FedProx también sube rápido en AUC pero su val_loss oscila bastante en las primeras rondas y no se estabiliza hasta la ronda 7–8; necesita las 10 rondas completas para terminar de encontrarse.

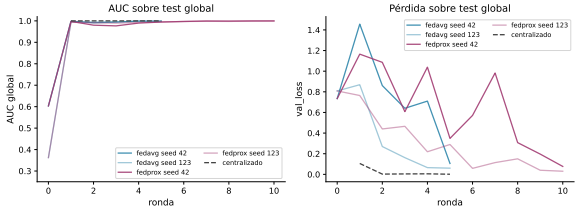


Fig. 3. Trayectorias de AUC y val_loss sobre el test global por ronda.

Análisis por hospital

Las Figuras 4 y 5 detallan las cuatro métricas por hospital a lo largo de las rondas para FedAvg y FedProx (semilla 42).

Con FedAvg los cuatro hospitales convergen de forma parecida. La especificidad arranca en 0 porque el modelo empieza prediciendo casi siempre EM (la clase mayoritaria en train), pero despega a partir de la ronda 3 y acaba por encima de 0,87 en todos los hospitales. H1 axial es el más lento, tiene sentido porque es el plano más distinto en el espacio del gradiente (coseno mínimo 0,525 frente a H3 sagital).

FedProx tiene el mismo problema inicial con la especificidad, pero tarda más en resolverlo. Esto ocurre porque el término proximal ancla cada cliente al modelo global, que al inicio es un predictor casi siempre-positivo. Con $\mu = 0{,}1$ el anclaje no es demasiado fuerte y el modelo acaba convergiendo, pero necesita bastantes más rondas. En ronda 5 la especificidad de FedProx en H1 es solo 0,63, mientras que FedAvg ya está en 0,88.

Equidad y métricas finales por hospital

La Figura 6 muestra la desviación estándar del AUC entre hospitales por ronda. FedAvg termina con $\sigma = 0{,}0048$ de media entre semillas, una dispersión muy baja del AUC entre el mejor y el peor hospital. FedProx llega a $\sigma = 0{,}0006$ al final de sus 10 rondas, una equidad mayor. En la Figura 7 casi todos los puntos quedan en la esquina superior derecha, con sensibilidad y especificidad altas; aun así hay dispersión: la especificidad de H1 con FedAvg baja hasta 0,88 con la semilla 42, y

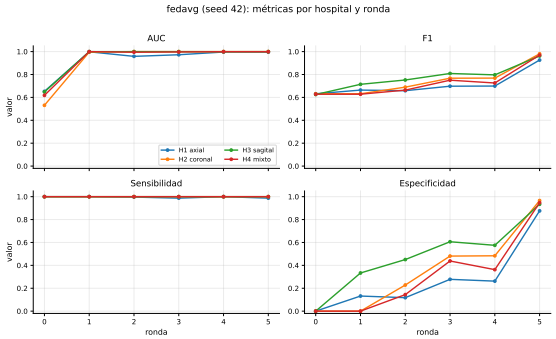


Fig. 4. FedAvg (semilla 42): AUC, F1, sensibilidad y especificidad del modelo agregado evaluado sobre cada hospital por ronda.

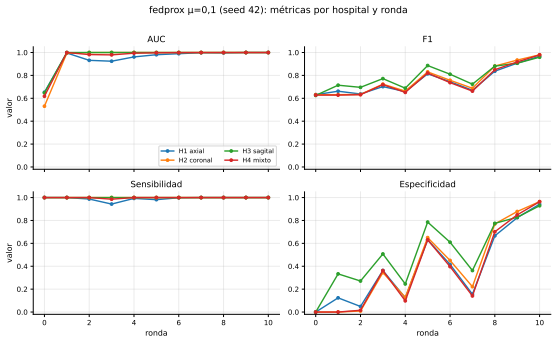


Fig. 5. FedProx $\mu = 0{,}1$ (semilla 42): mismas métricas en 10 rondas. La especificidad oscila en las primeras rondas y no se estabiliza hasta la ronda 7–8.

su sensibilidad hasta 0,90 con la 123. FedProx muestra un rango parecido.

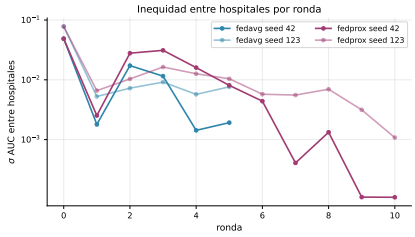


Fig. 6. Desviación estándar del AUC entre hospitales por ronda. Escala logarítmica.

La Tabla 5 detalla los resultados finales por hospital y semilla. El hospital más difícil depende del algoritmo: con FedAvg es H1 axial, que tiene el F1 más bajo (0,926–0,938); con FedProx (semilla 42) el más flojo es H3 sagital, con la especificidad (0,929) y el F1 (0,959) más bajos. H4 mixto queda en posición intermedia.

Coste de comunicación

Cada cliente intercambia con el servidor $2|\mathbf{w}| \times 4$ bytes, unos 85,3 MB por ronda (subida y bajada del modelo en *float32*); con los $K = 4$ clientes, el tráfico total

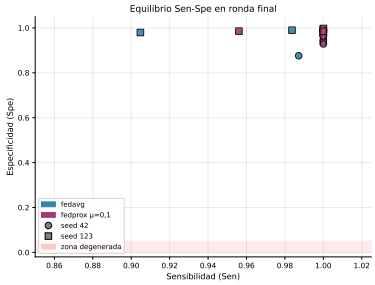


Fig. 7. Sensibilidad frente a especificidad en la ronda final, por algoritmo, semilla y hospital. La esquina superior derecha es el objetivo; la banda inferior es el predictor que siempre dice positivo.

Table 5. Métricas finales del modelo agregado por algoritmo, semilla y hospital.

Alg.	S.	Hospital	AUC	F1	Sen	Spe
FedAvg (r5)	42	H1 axial	0,9953	0,9261	0,9872	0,8760
		H2 coronal	1,0000	0,9805	1,0000	0,9659
		H3 sagital	0,9998	0,9619	1,0000	0,9341
		H4 mixto	0,9992	0,9694	1,0000	0,9467
	123	H1 axial	0,9820	0,9383	0,9048	0,9796
		H2 coronal	1,0000	0,9962	1,0000	0,9934
		H3 sagital	1,0000	0,9902	1,0000	0,9835
		H4 mixto	0,9986	0,9857	0,9837	0,9897
FedProx (r10)	42	H1 axial	0,9997	0,9672	1,0000	0,9419
		H2 coronal	1,0000	0,9798	1,0000	0,9646
		H3 sagital	0,9999	0,9589	1,0000	0,9286
		H4 mixto	0,9997	0,9791	1,0000	0,9639
	123	H1 axial	0,9975	0,9694	0,9560	0,9859
		H2 coronal	1,0000	0,9985	1,0000	0,9974
		H3 sagital	1,0000	0,9913	1,0000	0,9853
		H4 mixto	0,9999	0,9909	1,0000	0,9845

por ronda es de unos 341 MB. Con 5 rondas FedAvg acumula del orden de 1,7 GB, mientras que FedProx con 10 rondas necesita unos 3,4 GB para lograr resultados ligeramente mejores. El tiempo por ronda es de unos 138 s para todos los algoritmos; el término proximal de FedProx no añade tiempo apreciable. La Tabla 6 compara el coste total y el resultado final de cada algoritmo.

Table 6. Resumen de coste de comunicación y resultado final por algoritmo. *Tráfico total sumando los 4 clientes.

Método	Rondas	MB totales*	AUC final	F1 final
FedAvg	5	1 706	0,9980	0,9690
FedProx $\mu = 0{,}1$	10	3 413	0,9996	0,9799

Distancias entre hospitales

La Tabla 7 desglosa las métricas de heterogeneidad para cada par de hospitales. H1 axial es el más alejado del resto, especialmente de H3 sagital. H2 coronal y H3 sagital son los más similares (coseno de gradiente 0,879) al compartir la orientación superior-inferior del cerebro. H4 mixto queda en posición intermedia al

mezclar los tres planos a partes iguales.

Table 7. Métricas de heterogeneidad por par de hospitales. W1: Wasserstein-1; $\cos_{\text{emb}}$: coseno embeddings; $\cos_{\text{grad}}$: coseno gradientes.

Par	TV	Hellinger	W1	$\cos_{\text{emb}}$	$\cos_{\text{grad}}$	$\|\Delta g\|$
H1–H2	0,020	0,027	0,748	0,978	0,651	6,02
H1–H3	0,014	0,025	0,527	0,952	0,525	6,87
H1–H4	0,016	0,024	0,638	0,987	0,719	5,19
H2–H3	0,011	0,013	0,317	0,972	0,879	3,83
H2–H4	0,012	0,018	0,452	0,995	0,848	4,21
H3–H4	0,013	0,019	0,481	0,983	0,811	4,64
Media	0,015	0,022	0,527	0,977	0,739	5,11

Sobreajuste y detección de overfitting

Para detectar sobreajuste, en el código (`train_utils.py`) comparamos la pérdida de entrenamiento y la pérdida de validación en cada época local. Como el dataset no tiene una partición de validación separada, usamos las muestras de test solo para monitorizar; no tomamos ninguna decisión sobre los parámetros a partir de ellas. Para FedAvg la val_loss final es 0,106 para semilla 42 y 0,060 para semilla 123, ambas próximas a la train_loss, lo que indica una calibración correcta sin sobreajuste catastrófico. Para FedProx la val_loss oscila más en las primeras rondas pero se estabiliza en las últimas.

Rondas necesarias en FedProx

Ejecutar FedProx durante 5 rondas da resultados claramente peores que FedAvg en las mismas 5 rondas: la especificidad de H1 con FedProx en ronda 5 es solo 0,631 (semilla 42), frente a 0,876 de FedAvg. Con 10 rondas FedProx recupera y supera esa especificidad (0,942), pero al coste del doble de comunicación. La trayectoria de especificidad en H1 para FedProx semilla 42 muestra que la oscilación es real y no un artefacto de semilla: 0,000, 0,124, 0,049, 0,363, 0,124, 0,631, 0,416, 0,155, 0,666, 0,824 y 0,942. Por lo tanto, llegamos a la conclusión de que en despliegues con restricciones de comunicación, FedAvg es la única opción robusta de las dos.

5. CONCLUSIÓN

Los resultados confirman que la federación funciona bien en este escenario FTL. Los modelos federados generalizan a los cuatro planos anatómicos sin que ningún hospital tenga que ceder sus datos, y los resultados son comparables a los del entrenamiento centralizado en la mayoría de métricas.

FedAvg como opción robusta

FedAvg es la mejor opción en términos de relación rendimiento–coste en este escenario. Con solo 5 rondas alcanza AUC = 0,998 y F1 = 0,969, con una equidad entre hospitales de $\sigma = 0{,}005$. La Tabla 8 resume numéricamente las diferencias entre algoritmos para facilitar la comparación.

Table 8. Resultados de los algoritmos. Valores medios entre semillas 42 y 123. FedProx necesita 10 rondas; FedAvg usa 5.

Algoritmo	AUC	F1	Sen	Spe	σ AUC
FedAvg (5 r.)	0,9980	0,9690	0,984	0,960	0,0048
FedProx (10 r.)	0,9996	0,9799	0,994	0,970	0,0006
Centralizado	1,0000	0,9995	1,000	1,000	0,0000
Local-only	0,9451	0,7739	0,944	0,530	0,0343

La heterogeneidad moderada entre clientes (coseno de gradiente entre 0,5 y 0,9) no justifica algoritmos más complejos: cuando los clientes no se desvían en direcciones muy opuestas, la media ponderada de FedAvg es suficiente para obtener un buen modelo global.

Un resultado a destacar es que H1 axial es el hospital que más le cuesta a FedAvg. Las imágenes axiales son las más distintas del resto en el espacio del gradiente (coseno mínimo 0,525 frente a H3 sagital, frente a 0,879 entre H2 y H3). El modelo federado tarda más en clasificar bien el plano axial porque las actualizaciones de H1 apuntan en una dirección más alejada de la media que las del resto.

FedProx: mejor resultado final pero mayor coste

FedProx con $\mu = 0{,}1$ llega a resultados algo mejores que FedAvg (AUC = 0,9996, F1 = 0,980, $\sigma = 0{,}0006$), pero solo tras 10 rondas. El problema es que el término proximal ancla cada cliente al modelo global, que al inicio es un predictor casi siempre positivo porque arranca de pesos aleatorios y EM es la clase mayoritaria en entrenamiento. Ese anclaje frena la capacidad de los clientes para corregir la especificidad en las primeras rondas, produciendo la oscilación que se ve en la Figura 5. Con el doble de rondas y el doble de coste en comunicación (del orden de 3,4 GB frente a 1,7 GB de FedAvg), FedProx converge y supera ligeramente a FedAvg en las métricas finales. La pregunta práctica es si esa pequeña mejora justifica el coste extra; en este escenario, con heterogeneidad moderada, la respuesta es probablemente no.

Descubrimiento: la heterogeneidad real está en los gradientes

Quizás el resultado más interesante del proyecto no es el rendimiento de los algoritmos sino el análisis previo de heterogeneidad. Si nos hubiésemos quedado con las distancias entre histogramas de píxeles (TV = 0,015) o con las distancias entre embeddings (coseno = 0,977), habríamos concluido que los cuatro hospitales son casi idénticos y que la federación no es necesaria. Sin embargo, en el espacio del gradiente la similitud media es 0,739 con un mínimo de 0,525. Esto demuestra que para diagnosticar si un escenario de AF es realmente difícil hay que mirar las métricas del espacio de optimización, no solo las del espacio de entrada.

Limitaciones

Solo hemos simulado cuatro hospitales con distribución de clases equilibrada, que es un escenario poco exigente para el AF real. Con más clientes y mayor heterogeneidad los resultados podrían ser distintos: quizás FedProx sería más claramente mejor que FedAvg si el coseno de gradiente bajase de 0,4 o 0,3. Hemos usado solo dos semillas, así que la varianza está poco estimada. La etiqueta a nivel de paciente facilita la tarea respecto a lo que sería necesario clínicamente para detección lesión a lesión. La simulación en una sola máquina con actores Ray no captura latencias de red, clientes que se caen a mitad de una ronda (stragglers), ni heterogeneidad de hardware entre centros. Por último, no hemos evaluado el impacto del preprocesado KDE: si se usa sin él, la heterogeneidad en píxeles sería mucho mayor y los resultados podrían cambiar.

Trabajo futuro

La línea más directa sería probar FedProx con μ más pequeño (0,01 o incluso 0,001) para ver si converge en menos rondas manteniendo las métricas finales. También tiene sentido hacer un warmup de 2–3 rondas de FedAvg antes de activar el término proximal, de modo que el modelo global ya esté en un estado razonable cuando FedProx empiece a anclar.

A más largo plazo convendría ampliar el experimento a más hospitales con mayor variedad de heterogeneidad, comparar con algoritmos más recientes, y explorar si los resultados se mantienen cuando la tarea pasa de clasificación por paciente a un problema más complejo.

Reflexión sobre el escenario FTL

Desde el punto de vista docente, este proyecto ilustra bien por qué el FTL es más difícil que el HFL estándar. En HFL, la heterogeneidad entre clientes se puede medir fácilmente comparando las distribuciones de sus datos. En FTL, los datos de distintos clientes están en espacios de entrada diferentes y las métricas habituales de distancia en el espacio de píxeles o de representaciones no capturan la dificultad real del problema de optimización. Las métricas de gradiente son mucho más informativas porque miden directamente cuánto "tirarán" los clientes en direcciones distintas durante el entrenamiento.

También es interesante el resultado de que FedAvg, siendo el algoritmo más sencillo, sea el más adecuado cuando la heterogeneidad es moderada. FedProx, más complejo, añade un mecanismo pensado para situaciones de heterogeneidad alta, y cuando esa heterogeneidad no es tan grande ese mecanismo introduce más problemas que ventajas: el término proximal dificulta la calibración inicial sin aportar una mejora que compense el coste.

Finalmente, los resultados muestran que un sistema federado bien diseñado puede producir modelos que funcionan bien en todos los hospitales, con una desviación estándar del AUC entre centros de apenas $\sigma = 0{,}0048$ (con FedAvg). Esto es un resultado positivo para el objetivo de equidad entre centros, que es especialmente importante en aplicaciones médicas: no queremos que el modelo funcione muy bien en el hospital con más datos y muy mal en los demás.

6. REFERENCIAS

[1] B. McMahan, E. Moore, D. Ramage, S. Hampson y B. A. y Arcas, "Communication-efficient learning of deep networks from decentralized data," en *Proc. AISTATS*, 2017.

[2] T. Li, A. K. Sahu, A. Talwalkar y V. Smith, "Federated learning: Challenges, methods, and future directions," *IEEE Signal Process. Mag.*, vol. 37, n.º 3, pp. 50–60, 2020.

[3] G. A. Kaissis, M. R. Makowski, D. Rückert y R. F. Braren, "Secure, privacy-preserving and federated machine learning in medical imaging," *Nature Mach. Intell.*, vol. 2, n.º 6, pp. 305–311, 2020.

[4] T. Li, A. K. Sahu, M. Zaheer, M. Sanjabi, A. Talwalkar y V. Smith, "Federated optimization in heterogeneous networks," en *Proc. MLSys*, 2020.

[5] K. He, X. Zhang, S. Ren y J. Sun, "Deep residual learning for image recognition," en *Proc. CVPR*, pp. 770–778, 2016.

[6] D. J. Beutel *et al.*, "Flower: A friendly federated learning research framework," *arXiv:2007.14390*, 2020.

[7] A. Jung, *Federated Learning: From Theory to Practice*. Aalto, 2025.

[8] A. Jung, *Machine Learning: The Basics*. Springer, 2022.